

► Fazem de tempo constante é  $O(1)$   
• Melhor e mais rápido

### $O(1)$ - Constant Time:


```
def get_first_element(arr): return arr[0]
```




↳ Independente do input, o algoritmo vai demorar a mesma quantidade de tempo. Por isso é  $O(1)$ . Por exemplo: Pegar o primeiro elemento de um array.

### $O(n)$ - Linear Time:

$$\begin{matrix} \times \\ 2 \times \end{matrix} \quad \begin{matrix} 70 \\ 20 \end{matrix}$$



### $O(n \log n)$ - Linearithmic time:




Ex: MergeSort

→ Tempo de execução em 2 ou 3 passos  
→ Binary Search

### $O(\log n)$ - Logarithmic time:

$$2^{\log_2 n}$$



↳ Caso em que o tamanho do input aumenta  $n$ , o tempo de execução aumenta  $\log n$ . Sendo assim, eles não vão aumentar em uma proporção linear, mas sim em uma proporção logarítmica. Dessa forma, se o INPUT cresce muito mais rápido que o tempo de execução.

$$\log_2 10 = x$$

$$2^x = 10$$

$$x = 3.321$$

\* Lembrando que a representação  $O(\log n)$  serve para representar o pior caso (que aqui é quando estamos procurando o número 1). Lembrando que o número de passos não pode ser representado por um número decimal. Dessa forma, o pior caso é o pior cenário.

### $O(n^2)$ - Quadratic Time:



```
for i in range(n)
    for j in range(n)
```

### $O(2^n)$ - Exponential Time

```
def fibonacci(n):
    if n <= 1:
        return n
    else:
        return fibonacci(n-1) + fibonacci(n-2)
```



→ Para cada novo elemento a quantidade de passos dobra. Tempo exponencial escala terrivelmente mal com o tamanho do input.

### $O(n!)$ - Factorial Time

7 | 2

1 - 2 - 12 - 21

7 | 2 | 3

1 - 2 - 3 - 12 - 21 - 13 - 31 - 23 - 32



\* Considerar sempre o Pior dos casos (complexidade pessimista)